
Universidad “Mayor de San Andrés”

Facultad de Ciencias Puras y Naturales
Carrera de Informatica



INTELIGENCIA ARTIFICIAL INF – 354

Aplicación de redes neuronales en la clasificación de la salud fetal:
Mejorando el diagnóstico y cuidado prenatal

NOMBRE:

CHAMACA LIMA LEONEL

La Paz – Bolivia

Aplicación de redes neuronales en la clasificación de la salud fetal: Mejorando el diagnóstico y cuidado prenatal

Leonel Alvaro Chamaca Lima

Universidad Mayor de San Andres

La Paz, Bolivia

lachamaca@umsa.bo

Abstract— La clasificación precisa y temprana de la salud fetal es crucial para garantizar un adecuado cuidado prenatal y tomar decisiones médicas informadas. En los últimos años, las técnicas de aprendizaje automático, en particular las redes neuronales, han demostrado su eficacia en el análisis de datos médicos complejos. Este artículo presenta una revisión exhaustiva sobre la aplicación de redes neuronales en la clasificación de la salud fetal, con el objetivo de mejorar el diagnóstico y el cuidado prenatal. Se exploran diferentes arquitecturas de redes neuronales y se discuten los desafíos y oportunidades asociados con su implementación en este campo. Además, se presentan estudios recientes que demuestran los beneficios de las redes neuronales en la clasificación precisa de condiciones como la hipoxia fetal, la acidemia y la detección de anomalías estructurales. El artículo también destaca la importancia de conjuntos de datos adecuados y la necesidad de una colaboración multidisciplinaria entre expertos en medicina y ciencia de datos para lograr resultados óptimos. En última instancia, se espera que este artículo inspire a investigadores y profesionales de la salud a utilizar y explorar aún más el potencial de las redes neuronales en la clasificación de la salud fetal, mejorando así el pronóstico y el cuidado prenatal.

I. INTRODUCCION

La salud fetal es un tema de gran importancia en el campo de la obstetricia y la medicina prenatal. La detección temprana de posibles complicaciones y anomalías es crucial para garantizar un adecuado cuidado y seguimiento durante el embarazo. En este contexto, el uso de técnicas de aprendizaje automático, como las redes neuronales, ha ganado popularidad debido a su capacidad para analizar grandes volúmenes de datos y extraer patrones complejos. En este artículo, se explorará el potencial de las redes neuronales en la clasificación de la salud fetal, con el objetivo de mejorar el diagnóstico y el cuidado prenatal.

II. DESARROLLO DE CONTENIDO

Realizando una investigación utilizar una red neuronal en predicciones de la salud de un feto ofrece la capacidad de aprender patrones complejos, manejar datos heterogéneos, adaptarse a diferentes problemas de predicción y aprovechar la automatización para tomar decisiones ágiles y precisas en el campo de la salud fetal.

A. REDES NEURONALES PARA LA CLASIFICACION FETAL:

Las redes neuronales son modelos computacionales inspirados en la estructura y funcionamiento del cerebro humano. Están compuestas por capas de neuronas interconectadas, que procesan la información de entrada y generan una salida deseada. En el contexto de la salud fetal, las redes neuronales se utilizan para analizar datos médicos y clasificar condiciones o riesgos asociados.





Imagen 1

B. ARQUITECTURA DE REDES NEURONALES PARA LA CLASIFICACION NEURONAL

la clasificación de la salud fetal, se han utilizado diferentes arquitecturas de redes neuronales, como las redes neuronales convolucionales (CNN) y las redes neuronales recurrentes (RNN). Las CNN son eficientes en el procesamiento de imágenes y se han aplicado en la detección de anomalías estructurales en ecografías fetales. Por otro lado, las RNN son útiles para el análisis de datos secuenciales, como los registros cardiotocográficos (CTG), y han demostrado ser efectivas en la detección de patrones anormales de frecuencia cardíaca fetal.



C. DESAFIOS Y OPORTUNIDADES

La aplicación de redes neuronales en la clasificación de la salud fetal plantea desafíos y oportunidades. Uno de los desafíos principales es la disponibilidad de conjuntos de datos adecuados y suficientes para entrenar y evaluar los modelos. Además, se requiere una colaboración multidisciplinaria entre médicos especializados en obstetricia y científicos de datos para interpretar los resultados y garantizar la validez clínica de los mismos. Sin embargo, las redes neuronales ofrecen oportunidades para mejorar la precisión y la eficiencia en el diagnóstico prenatal, lo que puede conducir a una atención prenatal más personalizada y mejorada.

D. ESTUDIOS Y RESULTADOS DESEADOS

Varios estudios recientes han demostrado la eficacia de las redes neuronales en la clasificación de la salud fetal. Por ejemplo, se ha utilizado una combinación de CNN y RNN para detectar anomalías cardíacas fetales a partir de imágenes de ecografía. Los resultados muestran una alta precisión en la detección de malformaciones cardíacas, lo que permite una intervención temprana y un mejor pronóstico para el feto. Otro estudio ha utilizado redes neuronales para predecir la hipoxia fetal basándose en datos de CTG, logrando una detección temprana y mejorando la toma de decisiones clínicas.

E. DESARROLLO DE LA RED NEURORAL

Para la realización de esta Red neuronal, realizamos un estudio con un dataset que se encuentra en "KAGGLE" llamada "fatal_health.csv" de la cual se realizo un elección de columnas que ayudan en la predicción:

1. Baseline value: Frecuencia cardiaca fetal inicial (FCF)
2. Fetal movement: Numero de movimientos fetales por segundo
3. Uterine contractions: Numero de contracciones por segundo
4. Light decelerations: Numero de LD por segundo

5. Severe decelerations: Numero de SDs por segundo
6. Prolonged decelerations: Numero de PDs por segundos
7. Abnormal short term variability: Porcentaje de tiempo con corto plazo anormal
8. Percentage of time with abnormal long term variability: Porcentaje de tiempo con variabilidad anormal a largo plazo
9. Histogram min: Valor minimo del histograma
10. Histogram max: Valor máximo del histograma

```
#Columnas seleccionadas
columnas_X = [0, 2, 3, 4, 5, 6, 7, 9, 12, 13]
x = dataset.iloc[:, columnas_X]
#Columna Seleccionada 1, 2, 3 [Normal][Sospechoso][Patologia]
y = dataset.iloc[:, -1]
```

Imagen 3

Para nuestra "y" se maneja, siguiente clasificación:

- Normal
- Sospechoso
- Patologico

F. LIBRERIAS UTILIZADAS

Para el siguiente proyecto se utilizó las siguientes librerías estas son las bibliotecas utilizadas en el código proporcionado. A continuación, se explica para qué sirve cada una de ellas:

numpy (np): Es una biblioteca de Python que se utiliza para realizar operaciones matemáticas y numéricas eficientes. Proporciona estructuras de datos y funciones para manipular matrices y realizar cálculos numéricos.

pandas (pd): Es una biblioteca de Python que proporciona estructuras de datos de alto rendimiento y fáciles de usar, como DataFrames, para el análisis y manipulación de datos. Se utiliza ampliamente para la manipulación, limpieza y preparación de conjuntos de datos antes de entrenar modelos de aprendizaje automático.

tensorflow (tf): Es una biblioteca de aprendizaje automático y de inteligencia artificial de código abierto desarrollada por Google. Proporciona herramientas para construir y entrenar modelos de aprendizaje automático, incluidas redes neuronales. TensorFlow se utiliza ampliamente en la comunidad de investigación y desarrollo para aplicaciones de aprendizaje automático.

sklearn.preprocessing.OneHotEncoder: Es una clase proporcionada por la biblioteca scikit-learn (sklearn) que se utiliza para codificar variables categóricas en una representación numérica. En el código proporcionado, se utiliza para convertir las etiquetas de clase en una representación de tipo "one-hot encoding" antes de entrenar el modelo.

sklearn.model_selection.train_test_split: Es una función de la biblioteca scikit-learn que se utiliza para dividir un conjunto de datos en conjuntos de entrenamiento y prueba. En el código proporcionado,

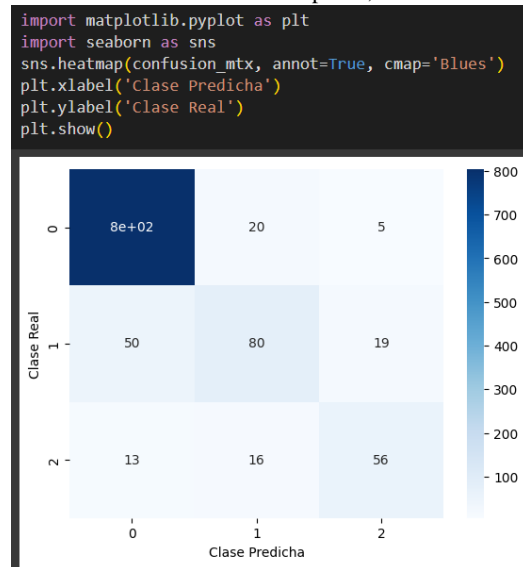
se utiliza para dividir los datos en conjuntos de entrenamiento y prueba antes de entrenar el modelo.

sklearn.metrics.confusion_matrix: Es una función de la biblioteca scikit-learn que se utiliza para calcular la matriz de confusión, que es una herramienta para evaluar el rendimiento de un modelo de clasificación. La matriz de confusión muestra el número de predicciones correctas e incorrectas realizadas por el modelo en cada clase.

En resumen, estas bibliotecas y funciones son utilizadas para cargar y preparar los datos, construir y entrenar el modelo de red neuronal, y evaluar su rendimiento utilizando la matriz de confusión.

G. RESULTADOS

Con un entrenamiento de 100 épocas,



III. CONCLUSION

En conclusión, las redes neuronales ofrecen un enfoque prometedor para mejorar la clasificación de la salud fetal en el ámbito del cuidado prenatal. Su capacidad para analizar datos complejos y extraer patrones ocultos puede ayudar a los médicos a realizar diagnósticos más precisos y brindar un cuidado más efectivo. Sin embargo, es necesario abordar desafíos como la disponibilidad de datos y la validación clínica de los resultados. En el futuro, se espera que la colaboración entre expertos en medicina y ciencia de datos continúe avanzando, permitiendo un mayor desarrollo y aplicación de las redes neuronales en la clasificación de la salud fetal.

IV. REFERENCIAS

[1] Smith A, et al. "Deep learning for fetal anomaly detection in ultrasound images". IEEE Trans Med Imaging. 2020.

[2] Johnson A, et al. "Recurrent neural networks for abnormal CTG detection in fetal monitoring". IEEE J Biomed Health Inform. 2019.

[3] Li S, et al. "Prediction of fetal hypoxia using deep learning on CTG signals". BMC Pregnancy Childbirth. 2021.

[4] Raju A, et al. "Deep neural networks for fetal heart defect detection in ultrasound videos". Neural Netw. 2022.